

REGISTRE CENTRAL DES MALADIES RARES (CRRD)

Rapport de benchmark sur la qualité des données
(1^{ère} Édition: 2015 – 2025)

—

A PROPOS DE SCIENSANO

Sciensano est un institut scientifique public et indépendant, qui œuvre pour la santé de l'homme et de l'animal et leur environnement.

Nous faisons de la recherche scientifique et de la surveillance et nous soutenons les autorités et différentes agences et organisations par des avis et des services et au travers de notre expertise en matière de santé.

Sciensano accorde une grande importance au principe One Health qui met en exergue que la santé de l'homme, la santé de l'animal et leur environnement sont étroitement liés.

C'est pour cette raison que notre recherche est interdisciplinaire et qu'elle intègre différentes perspectives.

Avec plus de mille collaborateurs et 120 ans d'expertise scientifique, Sciensano est un établissement scientifique de renom, qui fait partie de plusieurs réseaux scientifiques internationaux.

Sciensano
Épidémiologie et Santé Publique - Étude des Soins de Santé
CRRD

Avril 2026 • Bruxelles • Belgique
Numéro de Rapport: D/2026.14.440/31

AMINA JIRARI, MSC

EVY DHONDT, PHD

NINA DEMEULEMEESTER, PHD

JOKE WUYTS, PHD

L'équipe CRRD

amina.jirari@sciensano.be • T +32 2 642 58 03
evy.dhondt@sciensano.be • T +32 2 642 55 81

Avec le support financier de



Merci de citer cette publication comme suit : Jirari A, Dhondt E, Demeulemeester N, Wuyts J. Registre Central des Maladies Rares (CRRD), Rapport de benchmark sur la qualité des données (1^{ère} Édition 2015–2025). Bruxelles, Belgique: Sciensano; 2026. 40 p. Numéro de Rapport: D/2026.14.440/31.

Remerciements

La première édition du Rapport de benchmark sur la qualité des données du Registre Central des Maladies Rares (CRRD, Central Registry of Rare Diseases) reflète les efforts conjoints de nombreuses personnes et institutions qui ont contribué, au cours de la dernière décennie, à la construction et au maintien du registre national belge des maladies rares. Ce qui a débuté comme une initiative ambitieuse visant à collecter de manière systématique des données sur les maladies rares est devenu un réseau de collecte de données robuste et coordonné, soutenant le suivi national, contribuant à l'élaboration des politiques publiques et renforçant la compréhension des maladies rares.

Nous adressons nos sincères remerciements à l'ensemble des anciens et actuels responsables de registre et gestionnaires de données du CRRD à Sciensano. Leur travail a permis d'assurer la continuité et la solidité opérationnelle de la collecte de données au fil du temps. Leur engagement dans la maintenance et la mise à jour des flux de données, le soutien aux fournisseurs de données et la mise en œuvre des Définitions de Collecte des Données (DCD, Data Collection Definition) a joué un rôle central dans le développement du registre.

Notre profonde gratitude s'adresse aux centres de génétique participants dont les données ont été analysées dans le cadre de ce rapport. Leurs équipes cliniques, administratives et de gestion des données consacrent des efforts soutenus à la transmission de données complètes et de qualité, souvent en parallèle d'une activité clinique exigeante et dans un contexte d'évolutions techniques constantes. Cet engagement mérite d'être souligné, d'autant plus que la participation au registre repose sur une démarche volontaire et sans mécanisme d'incitation. La contribution de ces centres constitue un pilier essentiel du CRRD et permet l'enrichissement continu des données nationales.

Nous remercions également nos partenaires institutionnels et collaborateurs, en particulier le Service public fédéral Santé publique, Sécurité de la chaîne alimentaire et Environnement (SPF Santé publique), l'équipe Healthdata.be, ainsi que l'ensemble des acteurs impliqués dans la conception, le soutien et la maintenance du cadre de collecte de données du CRRD. Leur expertise, leurs orientations et leur appui technique contribuent à garantir l'alignement du registre avec les cadres nationaux et les besoins opérationnels.

Nous adressons des remerciements tout particuliers à l'Institut National d'Assurance Maladie-Invalidité (INAMI), dont le soutien financier durable permet le fonctionnement, la consolidation et le développement progressif de l'infrastructure de collecte de données du CRRD.

Enfin, nous souhaitons exprimer notre reconnaissance aux patients et à leurs familles, dont les données constituent le fondement même de ce registre. Leur volonté de contribuer est essentielle, tant pour l'avancement des connaissances que pour le renforcement de la réponse nationale aux maladies rares. Nous remercions également RaDiOrg, l'organisation nationale belge des patients atteints de maladies rares, pour son engagement constant, son action de représentation et son rôle clé dans la sensibilisation aux enjeux des maladies rares.

Ce rapport est l'aboutissement de cet engagement partagé. Nous remercions l'ensemble des parties prenantes pour la confiance accordée, la collaboration continue et la mobilisation collective en faveur d'une meilleure connaissance des maladies rares et d'une amélioration durable de la prise en charge des patients en Belgique.

L'équipe CRRD

RÉSUMÉ

Cette première édition du Rapport de benchmark sur la qualité des données présente une vue d'ensemble de la qualité des données relatives aux maladies rares collectées par sept centres belges de génétique agréés entre 2015 et 2025, dans le cadre de l'Architecture 1 du Registre Central des Maladies Rares (CRRD).

Le rapport se compose de deux volets complémentaires :

1. **Une analyse agrégée au niveau global** décrivant les tendances générales de la qualité des données à travers les centres (Partie I), et
2. Un **rapport de benchmarking confidentiel spécifique à chaque centre**, fournissant des analyses comparatives **pseudonymisées** afin de soutenir l'amélioration interne de la qualité et l'harmonisation des pratiques (Partie II).

Les objectifs de ce rapport sont les suivants :

- Évaluer l'exhaustivité, la validité et la fiabilité, la cohérence et la qualité des données du CRRD ;
- Identifier les domaines de convergence et de variabilité entre les centres de génétique ;
- Soutenir des pratiques d'enregistrement harmonisées au moyen d'un retour constructif et fondé sur des données probantes ;
- Renforcer la fiabilité et la comparabilité des informations nationales relatives aux maladies rares à des fins épidémiologiques et de politiques publiques.

Au niveau agrégé global, le jeu de données du CRRD s'est progressivement élargi entre 2015 et 2025, atteignant **76 894 enregistrements** correspondant à **21 963 patients uniques**, sur base de **l'ensemble des soumissions brutes reçues avant toute validation et nettoyage des données**. Cette évolution reflète l'intégration progressive des centres et la consolidation des pratiques d'enregistrement.

L'exhaustivité des données était systématiquement élevée pour les variables d'identification (100,0 %) et celles liées aux consultations (93,2 %), tandis que les informations diagnostiques présentaient une exhaustivité plus faible (76,7 %), traduisant la complexité et l'hétérogénéité intrinsèques du diagnostic des maladies rares.

Les indicateurs globaux de **validité et de cohérence** témoignent d'un niveau élevé de **fiabilité des données**, la grande majorité des variables présentant des taux d'erreur inférieurs à 1 %. Les variables nécessitant un degré de standardisation plus élevé — telles que les codes postaux, les classes d'âge et le codage des maladies — concentrent la majorité des problèmes de validation observés. Sur l'ensemble de la période analysée, les **ORPHAcodes** sont demeurés le système de classification des maladies prédominant, tandis que SNOMED CT, OMIM, HPO et la ICD-10 ont été utilisés soit comme systèmes autonomes, soit en combinaison avec les ORPHAcodes, reflétant l'évolution des pratiques de codage et les efforts en matière d'interopérabilité.

Les **résultats de la validation** indiquent une amélioration progressive de l'efficacité de l'enregistrement au fil du temps, mise en évidence par l'augmentation des taux de validation dès la première soumission et par l'alignement progressif sur les versions successives de la Définition de la Collecte de Données (DCD). Parallèlement, les resoumissions répétées traduisent à la fois une application rigoureuse des règles de validation et la charge de travail associée pour les fournisseurs de données.

Si **les tendances agrégées globales montrent une convergence générale et une maturation progressive de la qualité des données du CRRD**, des **variations entre centres persistent dans certains domaines**, notamment les stratégies de codage diagnostique, l'utilisation des valeurs « inconnu » et l'exhaustivité de certains champs obligatoires. Ces différences sont examinées en détail dans les rapports de **benchmarking spécifiques à chaque centre** et doivent être interprétées à la lumière du système de classification principal utilisé par chaque centre, des flux de travail locaux, de la disponibilité des données dans les dossiers médicaux électroniques, des contraintes en ressources, ainsi que de l'hétérogénéité clinique et de la complexité des maladies rares. En outre, les spécifications intrinsèques de la DCD et certaines limitations techniques connues doivent également être prises en compte.

Les résultats de ce rapport visent à favoriser un dialogue constructif, à orienter les actions d'amélioration de la qualité et à soutenir le développement continu d'un système national robuste de surveillance des maladies rares.

TABLE DES MATIÈRES

Remerciements	ii
Résumé	iii
Table des matières.....	iv
Liste des acronymes et d'abréviations	v
Liste des tables	vi
Liste des figures.....	vii
PARTIE I Aperçu global de la qualité des données du CRRD	i
1. Introduction	1
1.1. Structure du rapport.....	1
1.2. Contexte et objectifs	1
1.3. Portée de la partie I.....	2
1.4. Structure de la partie I	2
2. Aperçu du jeu de données	3
2.1. Portée du registre et cadre de la collecte de données	3
2.1.1. Définition des cas et critères d'inclusion.....	3
2.1.2. Fournisseurs de données	3
2.1.3. Flux de données	4
2.2. Composition du jeu de données et évolution des métadonnées.....	6
2.3. Tendances de reporting	7
3. Évaluation globale de la qualité des données	9
3.1. Méthodologie	9
3.2. Exhaustivité	10
3.2.1. Valeurs manquantes.....	10
3.2.2. Utilisation des valeurs « inconnu ».....	12
3.3. Validité et fiabilité	13
3.4. Cohérence	16
3.5. Qualité du codage des maladies	17
3.5.1. Aperçu général.....	17
4. Analyse globale du processus de validation	19
4.1. Méthodologie	19
4.2. Indicateurs du processus de validation.....	20
4.2.1. Tendances globales de validation	20
4.2.2. Tendances de validation liées au codage des maladies	22
5. Synthèse des principaux résultats	24
6. Conclusion.....	25
7. Références	26

LISTE DES ACRONYMES ET D'ABBRÉVIATIONS

BE	Belgique
CRRD	Central Registry of Rare Diseases, Registre Central des Maladies Rares
CSV	Comma-Separated Values, Valeurs Séparées par des Virgules
DCD	Data Collection Definition, Définitions de Collecte des Données
DSE	Dossier de Santé Électronique
DWH	Data Warehouse, Entrepôt de Données
HD4DP	Healthdata for Data Providers, Healthdata pour Fournisseurs de Données
HD4RES	Healthdata for Researchers, Healthdata pour Chercheurs
HGVS	Human Genome Variation Society (Nomenclature)
HMIS	Health Management Information System
HPO	Human Phenotype Ontology
ICD-10	International Classification of Diseases, 10th Revision
ICD-O	International Classification of Diseases for Oncology
INAMI	Institut National d'Assurance Maladie Invalidité
ISCN	International System for Human Cytogenomic Nomenclature
LIMS	Laboratory Information Management System
NISS	Numéro d'Identification à la Sécurité Sociale
OMIM	Online Mendelian Inheritance in Man
POC	Proof of Concept, Preuve de Concept
RDFs	Rare Disease Functions, Fonctions Maladies Rares
SAS	Statistical Analysis Software
SCRA	Small Cell Risk Analysis, Évaluation du Risque Lié aux Petites Cellules
SIH	Système d'Information Hospitalière
SPF Santé Publique	Service public fédéral Santé publique, Sécurité de la chaîne alimentaire et Environnement

LISTE DES TABLES

Tableau 1. Intégration technique des huit centres de génétique agréés.	4
Tableau 2. Aperçu des variables collectées dans le CRRD (v1.2 – v3.0).....	6
Tableau 3. Nombre total annuel d’enregistrements et de patients uniques soumis au CRRD (2015–2025).	7
Tableau 4. Aperçu des dimensions de la qualité des données, des définitions et des approches d’évaluation dans le CRRD.	9
Tableau 5. Exhaustivité moyenne des variables obligatoires par domaine dans les enregistrements du CRRD (%).	10
Tableau 6. Exhaustivité moyenne des variables dans les enregistrements du CRRD (%).	11
Tableau 7. Pourcentage total de valeurs « inconnu » par variable sélectionnée dans les enregistrements du CRRD (%).	12
Table 8. Synthèse des indicateurs de validité et de fiabilité par domaine de variables (%).	14
Table 9. Synthèse des indicateurs de cohérence inter-champs dans le CRRD (%).	16
Table 10. Répartition des systèmes de codage des maladies et des ontologies utilisés dans le CRRD.	17
Table 11. Indicateurs annuels du processus de validation et distribution globale du statut des enregistrements (2015–2025).	21

LISTE DES FIGURES



Figure 1. Flux de données dans le CRRD sous l'Architecture 1 de Healthdata.be.	5
Figure 2. Évolution annuelle du nombre de patients uniques soumis au CRRD (2015–2025).	8
Figure 3. Aperçu du flux de validation des données à deux niveaux appliqué dans le CRRD (Architecture 1).	20
Figure 4. Répartition des validations à la première tentative et à tentatives multiples (2015–2025).	22
Figure 5. Proportion des corrections de validation liées aux problèmes d'ORPHAcode (2015–2025).	23

PARTIE I

Aperçu global de la qualité des données du CRRD

1. INTRODUCTION

1.1. STRUCTURE DU RAPPORT

Ce Rapport de benchmark sur la qualité des données du CRRD est organisé en deux volets complémentaires :

Partie I : Aperçu global de la qualité des données

Cette partie présente des indicateurs agrégés de qualité des données pour l'ensemble des centres de génétique contributeurs. Elle offre une vue globale de l'exhaustivité, de la validité et de la fiabilité, de la cohérence, de la qualité du codage des maladies ainsi que des indicateurs du processus de validation, et est accessible à l'ensemble des parties prenantes impliquées dans les politiques relatives aux maladies rares, la recherche, la planification des services de santé et les organisations de patients.

Partie II : Rapport de benchmark sur la qualité des données spécifique à chaque centre

Chaque centre de génétique participant reçoit un rapport individuel et confidentiel contenant ses propres indicateurs détaillés de qualité des données ainsi que des comparaisons pseudonymisées avec les tendances globales. Ces analyses ciblées visent à soutenir le suivi interne de la qualité des données et l'amélioration continue, sans permettre l'identification entre centres. Une analyse comparative des flux de travail cliniques et organisationnels entre centres ne relève pas de la portée de ce rapport.

1.2. CONTEXTE ET OBJECTIFS

Le CRRD a été développé par Sciensano afin de fournir un cadre national pour l'enregistrement standardisé et le suivi des maladies rares en Belgique. Son objectif est de consolider les informations collectées auprès des centres de génétique agréés et des Fonctions Maladies Rares (RDFs, Rare Disease Functions) au sein d'une base de données nationale unique et harmonisée, soutenant la surveillance, la recherche, la planification des services de santé et l'évaluation des politiques.

Ce rapport présente une évaluation globale de la qualité et de l'exhaustivité des données pour l'ensemble des enregistrements de patients soumis dans le cadre de l'Architecture 1 du CRRD entre 2015 et 2025, correspondant aux versions v1–v3 mises en œuvre via Healthdata.be. Durant cette période, seuls les centres de génétique¹ ont contribué aux données du registre. Les RDFs ont été intégrées ultérieurement, en septembre 2024, dans le cadre de l'Architecture 2 (v5), et seront incluses dans les cycles de reporting futurs. Leurs données ne font donc pas partie de cette analyse.

Les chiffres présentés dans ce rapport reflètent les enregistrements bruts, non nettoyés, reçus via l'Architecture 1, incluant à la fois les soumissions initiales ainsi que les resoumissions générées dans le cadre de la boucle de validation. Ils ne représentent pas l'ensemble final des enregistrements validés stockés dans l'entrepôt de données (DWH, Data Warehouse) du CRRD. Pour des données nettoyées, validées et entièrement contrôlées en termes de qualité, veuillez vous référer au Rapport de collecte de données du CRRD².

¹ Ces centres correspondent aux centres de génétique agréés en Belgique, tels que définis par l'Arrêté royal de 2008 établissant le réseau des services de génétique médicale.

² Dhondt E, Jirari A, Demeulemeester N, Wuyts J. Central Registry of Rare Diseases (CRRD), Data Collection Report (1st Edition 2015–2025). Brussels, Belgium: Sciensano; 2026. 97 p. Report reference number: D/2026.14.440/6.

1.3. PORTÉE DE LA PARTIE I

La Partie I de ce rapport fournit une évaluation globale de la qualité des données pour l'ensemble des enregistrements soumis dans le cadre de l'Architecture 1 du CRRD. Ses objectifs sont les suivants :

- Analyser les tendances globales au fil du temps des soumissions au registre (2015–2025) ;
- Évaluer l'exhaustivité, la validité et la fiabilité, la cohérence et la qualité du codage des maladies des données du CRRD ;
- Évaluer les principaux indicateurs liés au processus de validation des données du CRRD ;
- Identifier les domaines de convergence et de variabilité entre les centres de génétique ;
- Mettre en évidence les défis communs en matière de qualité des données liés à la collecte de données, à la validation et au codage des maladies ;
- Fournir une base factuelle pour soutenir des pratiques d'enregistrement harmonisées et l'amélioration continue des processus de saisie et de validation des données.

Dans ce rapport, le terme **collecte de données** fait référence à la disponibilité et à l'enregistrement des informations au niveau de la source (par exemple, les dossiers de santé électronique– DSE), tandis que le terme **saisie des données** désigne la soumission ou la transcription ultérieure de ces informations dans le CRRD via les outils de soumission du registre. Les aspects techniques du flux de données et du processus de soumission sont décrits à la Section 2.3.

En parallèle, un rapport de benchmark spécifique est produit pour chaque centre de génétique (Partie II). Ces rapports confidentiels fournissent des évaluations détaillées ainsi que des indicateurs de comparaison pseudonymisés afin de soutenir l'amélioration de la qualité des données au niveau des centres.

1.4. STRUCTURE DE LA PARTIE I

Cette première partie offre une vue d'ensemble complète du jeu de données du CRRD, en contextualisant le périmètre du registre, les fournisseurs de données et la période de reporting. Elle introduit les chapitres suivants :

1. **Introduction** : Présentation de la structure du rapport, des objectifs, de la portée et de l'organisation de la Partie I.
2. **Aperçu du jeu de données** : Synthèse de l'activité de reporting des centres participants au fil du temps.
3. **Évaluation globale de la qualité des données** : Analyse de l'exhaustivité, de la validité et de la fiabilité, de la cohérence et de la qualité du codage des maladies à partir d'indicateurs agrégés pour l'ensemble des centres participants.
4. **Analyse globale du processus de validation** : Présentation des indicateurs du processus de validation et des tendances liées au codage des maladies pour l'ensemble des centres participants.
5. **Synthèse des principaux résultats** : Interprétation globale des points forts et des domaines nécessitant des efforts supplémentaires d'harmonisation.
6. **Conclusion** : Synthèse des résultats et perspectives d'évolution.
7. **Références** : Documentation de support et notes méthodologiques.

2. APERÇU DU JEU DE DONNÉES

Cette section présente le volume global et l'évolution des soumissions de données collectées dans le CRRD entre 2015 et 2025, en combinant l'ensemble des centres de génétique participants dans le cadre de l'Architecture 1 (v1–v3). Elle décrit d'abord **la portée du registre et le cadre de collecte des données**, y compris la définition des cas, les fournisseurs de données participants et le flux de données. Elle résume ensuite **la composition du jeu de données** ainsi que **les tendances des soumissions de données au fil du temps**.

2.1. PORTÉE DU REGISTRE ET CADRE DE LA COLLECTE DE DONNÉES

2.1.1. DÉFINITION DES CAS ET CRITÈRES D'INCLUSION

La population cible du CRRD comprend l'ensemble des personnes atteintes d'une maladie rare dont le parcours de soins implique un centre de génétique agréé ou une RDF en Belgique, que ce soit par le biais d'une consultation directe ou par l'analyse d'échantillons biologiques réalisée par le centre. Dès lors qu'un diagnostic est établi, le patient devient éligible à l'enregistrement dans le CRRD.

La définition de cas précise les critères d'inclusion et d'exclusion applicables à l'enregistrement dans le CRRD et se formule comme suit :

1. Le patient présente un **diagnostic de maladie rare**, de **maladie génétique rare** ou de **cancer rare**.
2. Le patient est **symptomatique**; les personnes asymptomatiques ou les porteurs sains ne sont pas éligibles.
3. L'**enregistrement intervient après la naissance**, permettant au patient de participer activement au système de soins. Les diagnostics prénataux, les décès prénataux et les mortinaissances ne sont pas enregistrés.
4. Tout cas répondant aux **critères susmentionnés** doit faire l'objet d'un enregistrement.

Précisions complémentaires concernant la définition des cas:

- Le diagnostic peut être établi sur la base d'une évaluation clinique et/ou confirmé par des analyses génétiques ou biologiques.
- Les données peuvent être collectées au moment de l'évaluation diagnostique, ainsi que lors du suivi ou d'autres consultations cliniques.
- Pour l'inventaire, la classification et la référence des maladies, le CRRD s'appuie sur [Orphanet](#), portail international de référence consacré aux maladies rares et aux médicaments orphelins, destiné aux professionnels de santé et au grand public. L'inclusion d'une entité clinique dans la nomenclature Orphanet suppose, entre autres critères, que la maladie réponde à la définition européenne d'une maladie rare (c'est-à-dire qu'elle touche moins de 5 personnes sur 10 000).
- Aux fins du présent rapport, le terme **enregistrements** fait référence aux soumissions individuelles dans le CRRD, pouvant inclure plusieurs entrées pour un même patient (par exemple, soumissions répétées au fil du temps, mises à jour ou soumissions provenant de différents fournisseurs de données). Le terme **patients uniques** désigne les enregistrements au niveau patient après déduplication, où plusieurs enregistrements sont liés à un même individu via les procédures de pseudonymisation et de couplage du CRRD.

2.1.2. FOURNISSEURS DE DONNÉES

Le CRRD a été mis en œuvre progressivement à la suite de sa migration vers Healthdata.be en juillet 2015. L'intégration technique des huit centres nationaux de génétique s'est déroulée entre août 2015 et avril 2016, marquant le début des soumissions de données dans le cadre de l'Architecture 1 (v1–v3). L'ensemble des huit centres était censé contribuer aux données du registre.

Cependant, le Centre de Génétique Humaine de l'ULB n'a pas soumis de données au CRRD en raison de préoccupations liées à la protection des données soulevées par son comité d'éthique, et n'a donc pas été inclus dans ce cycle de reporting. Par conséquent, l'analyse présentée dans ce rapport couvre sept des huit fournisseurs de données initialement prévus.

Le Tableau 1 présente le calendrier d'intégration technique des centres de génétique, par ordre chronologique d'intégration dans la plateforme Healthdata.be.

Tableau 1. Intégration technique des huit centres de génétique agréés.

Fournisseurs de données	Intégration technique
UZ Antwerpen – Centrum Medische Genetica	18/08/2015
UZ Gent – Centrum voor Medische Genetica	16/09/2015
ULB – Centre de Génétique Humaine	21/10/2015
Institut de Pathologie et de Génétique	30/10/2015
CHU de Liège – Centre de Génétique Humaine	3/12/2015
Cliniques Universitaires Saint-Luc – Centre de Génétique Humaine	17/12/2015
UZ Brussel – Centrum voor Medische Genetica	14/01/2016
UZ Leuven – Centrum Menselijke Erfelijkheid	20/04/2016

2.1.3. FLUX DE DONNÉES

Le traitement des données dans le cadre de l'Architecture 1 suit le flux de travail standardisé développé par Healthdata.be, garantissant une collecte, un chiffrement, une validation et une analyse sécurisés des données dans l'ensemble des centres participants

Les fournisseurs de données collectent les informations directement à partir de leurs systèmes opérationnels locaux (par exemple, dossier de santé électronique (DSE), système de gestion des informations de laboratoire (LIMS, Laboratory Information Management System), système d'information hospitalière (SIH). Ces données sont ensuite rendues disponibles soit par extraction automatique de fichiers au format valeurs séparées par des virgules (CSV, Comma-Separated Values), soit par saisie manuelle, puis transmises de manière sécurisée à Healthdata.be via l'eHealthBox, la messagerie nationale chiffrée gérée par la plateforme eHealth.

La transmission s'effectue soit par intégration directe au système local, soit via le composant logiciel Healthdata pour fournisseurs de données (HD4DP, Healthdata for Data Providers), installé et géré localement par chaque centre. HD4DP est connecté au catalogue central des métadonnées (DCD, Data Collection Definition), qui contient les listes de variables spécifiques au projet, les jeux de valeurs et les règles de validation publiés par Healthdata.be³.

Avant leur transmission à Healthdata.be, les identifiants personnels, tels que le Numéro d'Identification à la Sécurité Sociale (NISS), sont pseudonymisés et chiffrés par la plateforme eHealth. Une étape supplémentaire de pseudonymisation est ensuite appliquée au sein de Healthdata.be afin d'assurer la cohérence entre les données historiques et les nouvelles données collectées, et de permettre des analyses longitudinales sous un schéma de pseudonymisation uniforme⁴. Les jeux de données chiffrés sont ensuite transmis à Healthdata.be, où un accusé de réception automatique est envoyé au fournisseur de données.

Les chercheurs et gestionnaires de données de Sciensano accèdent aux jeux de données soumis via la plateforme Healthdata pour chercheurs (HD4RES, Healthdata for Researchers). Dans cet environnement, ils suivent l'état des soumissions, réalisent des contrôles initiaux de validation des données et adressent des demandes de correction

³ Pour plus d'informations, veuillez consulter: <https://docs.healthdata.be/HDBP0008>.

⁴ Pour plus d'informations, veuillez consulter :

<https://www.ehealth.fgov.be/ehealthplatform/file/cc73d96153bbd5448a56f19d925d05b1379c7f21/8b1b2e5884f4b3bae0045e3f81cf5a030faca2/15-009-f102-hd4patient-modifiee-le-3-mars-2020.pdf>.

aux fournisseurs de données lorsque cela est nécessaire. Après validation et avant tout traitement analytique, une évaluation du risque lié aux petites cellules (SCRA, Small Cell Risk Assessment) est réalisée afin de garantir le respect des exigences légales, éthiques et de protection des données. Ce n'est qu'après ces étapes que les jeux de données validés sont intégrés dans la base de données centrale du CRRD pour analyse et reporting⁵.




Figure 1. Flux de données dans le CRRD sous l'Architecture 1 de Healthdata.be.

La Figure 1 illustre le flux de données complet de collecte et de gestion des données du CRRD, depuis la collecte de données dans les centres de génétique jusqu'au reporting national par Sciensano. Elle met en évidence les principales étapes ; enregistrement, chiffrement, suivi, validation, stockage et analyse, soutenues par une boucle de validation continue entre l'équipe de gestion du CRRD et les fournisseurs de données.

La validation des données au sein du CRRD suit un processus en deux étapes. Dans un premier temps, une **validation en amont** est réalisée au niveau du fournisseur de données via le composant HD4DP. À ce stade, les champs obligatoires, les règles de format et les ensembles de valeurs prédéfinis sont vérifiés automatiquement, empêchant la soumission d'enregistrements structurellement invalides à la plateforme centrale. Dans un second temps, une **validation en aval** est effectuée par l'équipe de gestion du CRRD dans l'environnement HD4RES. Ces contrôles portent sur la cohérence interne et la plausibilité des données soumises. Lorsque des incohérences ou des erreurs sont détectées, des demandes de correction sont adressées aux fournisseurs de données, qui peuvent corriger et resoumettre les enregistrements. Ce processus de validation itératif peut entraîner plusieurs soumissions pour un même patient unique.

Une analyse détaillée du processus de validation et des indicateurs associés est présentée au Chapitre 4 : Analyse globale du processus de validation.

⁵ Pour plus d'informations, veuillez consulter : <https://healthdata.sciensano.be/fr/l-architecture-technique-de-healthdata-be>.

2.2. COMPOSITION DU JEU DE DONNÉES ET ÉVOLUTION DES MÉTADONNÉES

Cette section présente un aperçu des **variables collectées dans le CRRD dans le cadre de l'Architecture 1 (v1–v3)**, ainsi que de **l'évolution des métadonnées du registre**, telles que définies dans les différentes versions successives de la DCD.

L'évolution des métadonnées du CRRD résulte d'un processus de développement itératif ayant débuté par une phase de preuve de concept (POC, Proof of Concept) menée entre décembre 2013 et juin 2015 avec deux centres pilotes (à savoir les centres de génétique affiliés au CHU de Liège et à l'UZ Gent). Cette phase a permis de réaliser les premiers tests techniques de l'infrastructure Healthdata.be. Les premiers retours et l'analyse des données issues du POC ont contribué à l'optimisation tant du jeu de données que des procédures de soumission, lesquelles ont ensuite été intégrées dans les mises à jour de la DCD.

À la suite de cette phase pilote, l'intégration technique des centres supplémentaires a débuté en 2015, et la majorité ont commencé une collecte régulière des données en 2016. Les retours issus de la mise en œuvre initiale du **CRRD v1.2** ont conduit à plusieurs améliorations de la structure des données et de leur faisabilité. Ces révisions ont été validées par le Comité de pilotage (2016) et le Collège belge de Génétique Humaine (2017), aboutissant à la publication de la version **CRRD v2.0**. Une mise à jour ultérieure, **CRRD v3.0**, a été lancée fin 2018 afin de résoudre les problèmes techniques restants et d'optimiser davantage le processus de collecte de données. Le Tableau 2 présente une synthèse des principales modifications des variables introduites au cours des trois versions.

Tableau 2. Aperçu des variables collectées dans le CRRD (v1.2 – v3.0).

Variable	Variable obligatoire dans la DCD v1.2	Variable obligatoire dans la DCD v2.0	Variable obligatoire dans la DCD v3.0
Identification			
Code INAMI unique du centre enregistreur	oui	oui	oui
Code INAMI unique du médecin spécialiste (pseudonymisé)	oui	oui	oui
Identifiant du patient (pseudonymisé)	oui	oui	oui
Date de naissance (SCRA)	oui	oui	oui
Sexe	oui	oui	oui
Lieu de résidence (SCRA)	oui	oui	oui
Décédé	non présent	non	non
Date de décès*	non	non	non
Pays de résidence	oui	oui	oui
Consultation			
Référé par (vers le centre d'enregistrement)	non présent	oui	oui
Pays de la référence	non présent	oui	oui
Service requis	non présent	non	oui
Date de première consultation dans le centre d'enregistrement	oui	oui	oui
Date du diagnostic actuel	non	non	non
Date de la consultation actuelle	non présent	oui	oui
Pays de la consultation actuelle	non présent	oui	oui
Ville de la consultation actuelle (SCRA)	non présent	oui	oui
Diagnostic			
Date des premiers symptômes (première consultation)	non	non	oui
Statut du diagnostic	oui	oui	oui

Base du diagnostic	oui	oui	oui
Diagnostic* : ORPHAcode ou autre code (par exemple ICD-10, SNOMED CT, ICD-O, HPO, OMIM, ISCN, HGVS)	au moins 1 système de codage requis	au moins 1 système de codage requis	au moins 1 système de codage requis
Diagnostic : Nom de la maladie	non présent	oui	oui
Référé vers (depuis le centre d'enregistrement)	non présent	Non	oui
Autre			
Consentement du patient pour la facilitation du recrutement	oui	non	non

Note: Pour plus de détails sur les variables, y compris les options de réponse correspondantes, veuillez consulter : <https://dcd.healthdata.be/en/collection/CRRD/>

Précisions supplémentaires sur les variables (*):

- La 'Date de décès' est une variable conditionnelle, affichée uniquement lorsque la variable précédente 'Décédé' est complétée par 'Oui'.
- La variable 'Diagnostic' peut être encodée à l'aide de plusieurs systèmes de classification des maladies ; bien qu'aucun système spécifique ne soit obligatoire, la nomenclature Orphanet est privilégiée, car elle est considérée comme le système le plus complet et le plus précis pour le codage des maladies rares⁶.

2.3. TENDANCES DE REPORTING

La période de reporting s'étend de juillet 2015 à juin 2025 et correspond à l'ensemble des enregistrements soumis et validés dans le cadre de l'Architecture 1. Sur cette période, un total de **76 894 enregistrements** a été collecté dans le CRRD, correspondant à **21 963 patients uniques**.

La différence entre le nombre total d'enregistrements et le nombre de patients uniques reflète principalement la boucle de validation intégrée dans le flux de travail du CRRD. Les centres ayant reçu un nombre plus élevé de demandes de correction génèrent souvent plusieurs resoumissions pour un même patient unique, ce qui entraîne une augmentation du nombre total d'enregistrements. Par ailleurs, certains centres ont soumis l'ensemble des consultations des patients plutôt qu'un seul enregistrement par patient, ce qui a également contribué à une augmentation du nombre total dans certaines années.

Le Tableau 3 présente une synthèse annuelle du nombre total d'enregistrements, ainsi que du nombre de patients uniques et validés soumis au CRRD au cours de cette période.

Tableau 3. Nombre total annuel d'enregistrements et de patients uniques soumis au CRRD (2015–2025).


Année	Total des enregistrements (N)	Patients Uniques (N)	Patients uniques (%)
2015	1	1	100,0
2016	10 802	374	3,5
2017	2 666	1 307	49,0
2018	3 792	706	18,6
2019	26 864	3 579	13,3
2020	9 521	4 737	49,8

⁶ Extrait du texte d'aide des DCD v1–v3: "Une maladie peut être décrite à l'aide de différents systèmes de codage. **La préférence est donnée à l'utilisation de la classification Orphanet, car il s'agit du système de classification le plus complet et le plus précis pour les maladies rares.** Si plusieurs systèmes de codage sont utilisés pour décrire la maladie, différents codes peuvent être introduits dans les champs correspondants. Il est obligatoire de remplir au moins un de ces champs...".

2021	2 320	949	40,9
2022	10 415	5 272	50,6
2023	4 070	2 793	68,6
2024	1 496	1 304	87,2
2025	4 947	941	19,0
Total	76 894	21 963	28,6

Afin de visualiser l'évolution des soumissions annuelles, la Figure 2 présente le nombre cumulé d'enregistrements totaux et de patients uniques par année, illustrant la trajectoire globale de croissance du registre entre 2015 et 2025.

Figure 2. Évolution annuelle du nombre de patients uniques soumis au CRRD (2015–2025).



La Figure 2 illustre l'**augmentation progressive** du nombre cumulé annuel d'enregistrements totaux et de patients uniques dans le cadre de l'Architecture 1 (2015–2025), reflétant à la fois l'intégration progressive des centres de génétique au registre (voir Tableau 1) et la poursuite des efforts d'enregistrement au fil du temps.

Une première augmentation substantielle du nombre cumulé total d'enregistrements a été observée en **2016**, lorsque l'ensemble des centres de génétique avait été intégré. Une seconde augmentation marquée est intervenue en **2019**, à la suite du lancement du CRRD v3 en 2018, qui a introduit une structure de données plus stable et facilité les soumissions de grande ampleur par les centres participants. La baisse observée entre **2020 et 2022** peut en partie refléter l'impact de la pandémie de COVID-19 sur l'activité clinique, la saisie des données et les flux de validation. Les fluctuations observées entre **2023 et 2024** reflètent probablement des transitions de systèmes préalables à la migration vers l'Architecture 2 en 2024, tant au niveau de Healthdata.be que des fournisseurs de données.

Les données pour l'année **2025** sont incluses jusqu'en juin 2025 uniquement, correspondant à la clôture officielle de l'Architecture 1 ; les valeurs pour 2025 représentent donc des données partielles et doivent être interprétées avec prudence.

3. ÉVALUATION GLOBALE DE LA QUALITÉ DES DONNÉES

Le présent chapitre fournit une **évaluation agrégée de la qualité globale des données au sein du CRRD**, basée sur l'ensemble des 76 894 enregistrements soumis dans le cadre de l'Architecture 1 (v1–v3). L'analyse évalue les principales dimensions de la qualité des données (à savoir l'exhaustivité, la validité et la fiabilité, la cohérence et la qualité du codage des maladies) à l'échelle du registre dans son ensemble, indépendamment des fournisseurs de données individuels.

L'objectif de cette évaluation globale est d'analyser dans quelle mesure les données soumises au CRRD reflètent de manière fiable et cohérente les informations collectées au niveau de la source, d'identifier les problèmes de qualité récurrents ou systémiques, et de soutenir l'amélioration continue des processus de saisie des données, des règles de validation et des spécifications techniques.

3.1. MÉTHODOLOGIE

Le jeu de données utilisé pour cette évaluation comprend **l'ensemble des enregistrements soumis dans le cadre de l'Architecture 1, indépendamment de leur statut de validation**.

L'ensemble des indicateurs présentés dans ce chapitre est dérivé de programmes standardisés de qualité des données mis en œuvre dans le logiciel d'analyses statistiques SAS® 9.4 (SAS, Statistical Software Analysis). Ces contrôles basés sur des règles permettent de détecter les valeurs manquantes, les incohérences logiques, les erreurs de format ainsi que l'utilisation incorrecte ou incomplète des systèmes de codage des maladies (par exemple, ORPHAcode, ICD-10, SNOMED CT). Ces programmes évaluent quatre dimensions principales de la qualité des données : **l'exhaustivité, la validité et la fiabilité, la cohérence et la qualité du codage des maladies**, sur base de règles et de seuils prédéfinis. Chaque dimension est présentée dans le Tableau 4.

Tableau 4. Aperçu des dimensions de la qualité des données, des définitions et des approches d'évaluation dans le CRRD.

Dimension de la qualité des données	Définition	Approche d'évaluation
Exhaustivité	Mesure dans laquelle les variables obligatoires contiennent des valeurs non manquantes	Pourcentage d'enregistrements avec des données non manquantes par variable ou domaine
Validité et fiabilité	Degré de conformité des valeurs aux formats prédéfinis, aux listes de référence ou aux plages de valeurs attendues	Contrôles automatisés des formats et des plages de valeurs, validation par rapport aux tables de référence (par exemple, codes pays, codes postaux, logique des dates)
Cohérence	Cohérence logique entre variables liées au sein d'un enregistrement	Contrôles inter-champs pour identifier les contradictions ou combinaisons illogiques
Qualité du codage des maladies	Exactitude et exhaustivité du codage des maladies à l'aide de systèmes de classification standardisés	Vérification de la validité des codes et de l'alignement entre les libellés et les codes

L'ensemble des résultats est agrégé à travers les centres participants afin de fournir une **vue d'ensemble au niveau global**, permettant d'identifier des problèmes de qualité systémiques plutôt que des écarts spécifiques à un centre.

Les résultats détaillés par centre sont présentés dans les rapports de benchmark spécifiques à chaque centre (Partie II).

3.2. EXHAUSTIVITÉ

3.2.1. VALEURS MANQUANTES

Les indicateurs d'exhaustivité quantifient la proportion de variables obligatoires contenant des données valides et non manquantes dans l'ensemble du registre. Ils offrent une vue globale du niveau de complétude des informations requises pour chaque enregistrement de patient unique par les centres de génétique participants.

L'analyse a été réalisée sur l'ensemble des variables obligatoires des domaines Identification, Consultation et Diagnostic, selon le critère d'inclusion « obligatoire dans au moins une version » (voir Tableau 5).

Tableau 5. Exhaustivité moyenne des variables obligatoires par domaine dans les enregistrements du CRRD (%).

Domaine	Exhaustivité moyenne (%)	Variable la plus fréquemment manquante
Identification	100,0	Lieu de résidence
Consultation	93,2	Moment du diagnostic actuel
Diagnostic	76,7	Référé par le centre d'enregistrement vers

Note: : L'exhaustivité est calculée comme le pourcentage d'enregistrements comportant des valeurs non manquantes pour chaque variable au sein du domaine. Les pourcentages sont arrondis à une décimale. L'exhaustivité rapportée de 100,0 % pour le domaine Identification correspond à une valeur réelle de 99,99867 %, l'incomplétude résiduelle étant attribuable à des valeurs manquantes pour le code postal.

Globalement, les niveaux d'exhaustivité étaient les plus élevés pour les variables d'Identification, reflétant leur caractère obligatoire dans l'ensemble des versions du CRRD. Des niveaux plus faibles ont été observés dans les domaines Consultation et Diagnostic, où certaines variables ont été introduites ou reclassées comme obligatoires uniquement dans les versions plus récentes de la DCD (v3.0).

Afin de compléter les résultats agrégés par domaine, le Tableau 6 présente le pourcentage d'exhaustivité pour chaque variable individuelle incluse dans le CRRD.

Dans le **domaine Identification**, toutes les variables obligatoires ont atteint un niveau d'exhaustivité de 100,0 %, ce qui suggère que ces informations sont facilement disponibles dans les dossiers de santé électroniques (DSE). Cela contraste avec les autres domaines, où des niveaux d'exhaustivité plus faibles reflètent probablement une complexité accrue des variables et des difficultés à extraire ou à compléter rétrospectivement les informations requises.

Quant au **domaine Consultation**, les variables « *Moment du diagnostic actuel* » et « *Moment du diagnostic actuel : préciser* » présentent des niveaux d'exhaustivité plus faibles (82,5 % et 86,8 % respectivement). Cette situation est probablement liée à des difficultés de capture de cette information dans les DSE, nécessitant souvent une saisie manuelle ou une resoumission via la boucle de validation. Le niveau d'exhaustivité plus faible pour la variable « *Type de service demandé* » était attendu (84,7 %), car elle n'était obligatoire qu'à partir de la version DCD v3.0. En revanche, la variable « *Référé au centre d'enregistrement par* » présente également un niveau d'exhaustivité réduit, bien qu'elle soit obligatoire dans toutes les versions de la DCD. Cette divergence est probablement liée à un bug de validation en amont présent durant une partie de la période de reporting, où le champ était défini comme obligatoire dans HD4DP1 mais n'empêchait pas effectivement la soumission lorsqu'il était laissé vide. En conséquence, des valeurs incomplètes pouvaient être acceptées malgré la règle de validation définie.

Dans le **domaine Diagnostic**, la variable « *ORPHAcode* » présente une exhaustivité nettement plus faible (68,4 %). Ce résultat s'explique par une considération méthodologique : durant la période de reporting, les déclarants devaient fournir au moins un code de maladie, sans qu'un système de codage spécifique soit imposé. L'exhaustivité est néanmoins rapportée spécifiquement pour les ORPHAcodes dans cette section, en raison de l'accent mis sur ce système de classification dans les analyses ultérieures. Le très faible niveau d'exhaustivité observé pour la variable « *Référé par le centre d'enregistrement vers* » était attendu, cette variable n'ayant été introduite comme obligatoire qu'à partir de la version DCD v3.0. La variable « *Moment des premiers symptômes (première consultation)* » présente un niveau d'exhaustivité de 84,6 %, reflétant probablement la difficulté intrinsèque à capturer cette information en pratique clinique et/ou à l'extraire de manière fiable des DSE.

Tableau 6. Exhaustivité moyenne des variables dans les enregistrements du CRRD (%).

Variable	Variable obligatoire dans toutes les versions de la DCD	Exhaustivité moyenne (%)
Identification		
Pays de résidence	oui	100,0
Date de naissance	oui	100,0
Lieu de résidence	oui	100,0
Sexe	oui	100,0
Consultation		
Pays de la référence	oui	100,0
Ville de la consultation actuelle	oui	100,0
Pays de la consultation actuelle	oui	100,0
Référé au centre d'enregistrement par	oui	84,7
Moment du diagnostic actuel	non ^a	82,5
Type de service requis	non ^b	84,7
Date de la consultation actuelle	oui	100,0
Date de la première consultations dans le centre d'enregistrement	oui	100,0
Moment du diagnostic actuel : préciser	non ^{a,c}	86,8
Diagnostic		
Base du diagnostic	oui	98,3
Status diagnosis	oui	100,0
ORPHAcodes	min. 1 système de codage requis	68,4
Moment des premiers symptômes (première consultation)	non ^a	84,6
Diagnostic : nom de la maladie	oui	100,0
Référé par le centre d'enregistrement vers	non ^b	9,0

^a Non obligatoire en v1.2 et v2.0 ; obligatoire en v3.0.

^b Non présent en v1.2 ; non obligatoire en v2.0 ; obligatoire en v3.0.

^c Variable conditionnelle, applicable uniquement pour certaines valeurs de la variable précédente « Moment du diagnostic actuel »

Note: L'exhaustivité est calculée comme le pourcentage d'enregistrements comportant des valeurs non manquantes pour chaque variable.

Les variables présentant des niveaux d'exhaustivité inférieurs à la moyenne agrégée ont été analysées plus en détail dans les rapports de benchmark individuels élaborés pour chaque centre participant. Ces rapports fournissent un retour ciblé ainsi que des recommandations visant à soutenir l'harmonisation et l'amélioration continue des pratiques d'enregistrement des données au sein du CRRD.

3.2.2. UTILISATION DES VALEURS « INCONNU »

En complément des données manquantes, l'évaluation de l'exhaustivité a également pris en compte l'utilisation de la valeur « inconnu » pour les variables pour lesquelles cette option est explicitement prévue dans la DCD. Bien que les valeurs « inconnu » ne soient pas techniquement considérées comme manquantes, leur fréquence fournit des informations précieuses sur la disponibilité des données dans les DSE ainsi que sur la qualité des informations cliniques au moment de l'enregistrement.

Le Tableau 7 présente la proportion de valeurs « inconnu » enregistrées pour des variables clés dans les domaines Identification, Consultation et Diagnostic.

Tableau 7. Pourcentage total de valeurs « inconnu » par variable sélectionnée dans les enregistrements du CRRD (%).

Domain	Variable	Pourcentage total dans les enregistrements du CRRD	Interprétation
Identification	Sexe	0,03	La très faible proportion de valeurs « inconnu » indique que cette variable est documentée de manière quasi systématique.
Consultation	Référé au centre d'enregistrement par	0,00	En combinaison avec le niveau d'exhaustivité plus faible observé pour cette variable (84,7 %, voir Tableau 6), ce résultat suggère que, lorsque l'information n'était pas disponible, le champ était plus souvent laissé vide plutôt que complété avec la valeur « inconnu ».
Consultation	Type de service requis	0,00	En combinaison avec le niveau d'exhaustivité plus faible observé pour cette variable (84,7 %, voir Tableau 6), ce résultat suggère que, lorsque l'information n'était pas disponible, le champ était plus souvent laissé vide plutôt que complété avec la valeur « inconnu ».
Consultation	Moment du diagnostic actuel	36,52	En combinaison avec le niveau d'exhaustivité plus faible observé pour cette variable (82,5 %, voir Tableau 6), l'utilisation fréquente de la valeur « inconnu » suggère des difficultés à capturer cette information clinique, probablement en raison d'une disponibilité limitée ou d'une incertitude rétrospective dans le DSE.
Diagnostic	Moment des premiers symptômes (première consultation)	19,21	En combinaison avec le niveau d'exhaustivité plus faible observé pour cette variable (84,6 %, voir Tableau 6), l'utilisation fréquente de la valeur « inconnu » suggère des difficultés à capturer cette information clinique, probablement en raison d'une disponibilité limitée ou d'une incertitude rétrospective dans le DSE.
Diagnostic	Base du diagnostic	0,00	En combinaison avec le niveau d'exhaustivité plus élevé observé pour cette variable (98,3 %, voir Tableau 6), ce résultat suggère que l'information est généralement facilement

			disponible et systématiquement capturée dans le DSE.
Diagnostic	Référé par le centre d'enregistrement vers	0,00	En combinaison avec le faible niveau d'exhaustivité observé pour cette variable (9,0 %, voir Tableau 6), ce résultat suggère que, lorsque l'information n'était pas disponible, le champ était plus souvent laissé vide plutôt que complété avec la valeur « inconnu »

Bien que la valeur « inconnu » soit valide et autorisée, une proportion élevée peut indiquer une documentation incomplète ou une variabilité des pratiques de saisie des données entre les centres. En outre, des différences dans la disponibilité et la structuration des données entre les systèmes de DSE peuvent influencer la fréquence à laquelle la valeur « inconnu » est sélectionnée pour certaines variables. Par conséquent, bien que ces valeurs aient été considérées comme valides pour les calculs d'exhaustivité, elles ont été interprétées séparément des entrées entièrement documentées.

Afin d'améliorer l'interprétabilité des données, il est recommandé aux centres d'utiliser l'option « inconnu » uniquement lorsque l'information est réellement indisponible, et non comme valeur par défaut ou de substitution. Le suivi de la fréquence des valeurs « inconnu » au fil du temps peut permettre d'identifier les domaines dans lesquels la documentation clinique ou les consignes de saisie des données doivent être renforcées. Par ailleurs, des révisions périodiques du jeu de données, en adéquation avec les informations couramment disponibles dans les systèmes de DSE, peuvent également favoriser une collecte des données plus cohérente et pertinente entre les centres.

3.3. VALIDITÉ ET FIABILITÉ

À la suite de l'évaluation de l'exhaustivité, cette section examine la validité et la fiabilité des données enregistrées dans le CRRD à l'aide d'indicateurs de qualité des données.

Les **contrôles de validité** évaluent si les valeurs enregistrées **respectent des contraintes techniques et sémantiques prédéfinies**. Ils répondent à la question « La valeur est-elle autorisée ? » et vérifient la conformité aux formats attendus, aux listes de référence et aux plages de valeurs logiques. À titre d'exemple, il peut s'agir de dates enregistrées dans des formats valides, de valeurs d'âge dans des limites plausibles ou de codes de maladies appartenant à des systèmes de codage standardisés.

Les **contrôles de fiabilité** évaluent si les informations enregistrées sont **pertinentes et plausibles** d'un point de vue clinique et épidémiologique. Ils répondent à la question « L'information a-t-elle du sens ? » et portent sur la cohérence globale des valeurs, y compris la présence d'informations diagnostiques essentielles et l'alignement entre les éléments descriptifs et codés. À titre d'exemple, il peut s'agir de la présence d'un nom de maladie et/ou d'un code associé pour un diagnostic, ou de la plausibilité de l'âge rapporté au moment du diagnostic au regard du contexte clinique.

Ensemble, ces contrôles de qualité, réalisés lors de la validation en amont et en aval, permettent d'identifier des erreurs structurelles (par exemple, des dates ou des codes invalides), des incohérences logiques entre variables liées (par exemple, une date de naissance postérieure à une date de décès) ainsi que des valeurs ou combinaisons de valeurs non plausibles. Ces contrôles sont essentiels pour garantir que les données du CRRD soient non seulement complètes, mais également exactes et adaptées aux analyses agrégées et au benchmarking.

Un résumé des contrôles de validité et de fiabilité appliqués au jeu de données du CRRD est présenté dans le Tableau 8. Celui-ci fournit un aperçu des principaux domaines de variables évalués, des types d'erreurs détectés ainsi que de la proportion d'enregistrements concernés parmi l'ensemble des soumissions dans le cadre de l'Architecture 1 (v1-v3).

Table 8. Synthèse des indicateurs de validité et de fiabilité par domaine de variables (%).

Domaine	Type de contrôle	Indicateur de qualité de données	Pourcentage total d'enregistrements invalides ou non fiables dans le CRRD (%)
Identification	Fiabilité	Date de naissance postérieure à la date de décès	0,00
Identification	Validité	Code postal invalide (non présent dans la liste de référence)	1,50
Identification	Validité	Code pays invalide (non présent dans la liste de référence)	0,00
Consultation	Fiabilité	Première consultation antérieure à la date de naissance	0,21
Consultation	Fiabilité	Première consultation postérieure à la date de décès	0,11
Consultation	Fiabilité	Première consultation postérieure à la consultation actuelle	0,34
Consultation	Fiabilité	Première consultation dans le futur	0,05
Consultation	Fiabilité	Consultation actuelle dans le futur	0,03
Consultation	Validité	Format de date complète invalide	0,68
Consultation	Validité	Format d'année invalide	0,02
Consultation	Validité	Format mois-année invalide	0,02
Consultation	Validité	Format de tranche d'âge invalide	0,26
Consultation	Validité	Format d'âge gestationnel invalide	0,08
Consultation	Validité	Code pays invalide (consultation actuelle)	0,00
Consultation	Validité	Ville/code postal invalide (consultation actuelle)	0,70
Diagnostic	Validité	Format de date complète invalide	0,98
Diagnostic	Validité	Format d'année invalide	0,00
Diagnostic	Validité	Format mois-année invalide	0,01
Diagnostic	Validité	Format de tranche d'âge invalide	1,24
Diagnostic	Validité	Format d'âge gestationnel invalide	0,42
Diagnostic	Fiabilité	Absence de nom de maladie et de code de maladie	0,00

Diagnostic	Fiabilité	Code de maladie disponible mais absence de nom de maladie	0,00
Diagnostic	Fiabilité	Nom de maladie disponible mais absence de code de maladie	2,45
Diagnostic	Validité	ORPHAcode invalide	0,00
Diagnostic	Validité	Code HPO invalide	0,00
Diagnostic	Validité	Code ICD-10 invalide	93,92
Diagnostic	Validité	Code ISCN invalide	100,00
Diagnostic	Validité	Code OMIM invalide	0,00
Diagnostic	Validité	Code SNOMED CT invalide	0,00

Note: Les pourcentages sont calculés en utilisant comme dénominateur le nombre d'enregistrements pour lesquels la variable concernée a été renseignée. Pour les contrôles de validité des systèmes de codage (par exemple, ORPHAcodes, SNOMED CT), le dénominateur correspond au nombre total d'enregistrements du CRRD dans lesquels le code correspondant a été renseigné.

Le Tableau 8 indique que, dans le domaine Diagnostic, **la majorité des enregistrements comportaient à la fois un nom de maladie et au moins un code de maladie correspondant**. Globalement, 97,55 % des enregistrements incluaient un nom de maladie associé à au moins un code de maladie.

Cependant, 2,45 % des enregistrements contenaient **un nom de maladie sans code de maladie correspondant**. Ce schéma reflète des situations où une information descriptive sur la maladie était fournie sans l'identifiant codé associé.

Étant donné que la présence d'au moins un code de maladie est définie comme obligatoire, ces résultats suggèrent une **limitation de la validation en amont** durant une partie de la période de reporting, permettant la soumission d'enregistrements malgré un codage des maladies incomplet. Ce comportement indique un problème de validation au niveau du système plutôt qu'une omission systématique de saisie de données par les centres déclarants.

Il convient de noter qu'**aucun ORPHAcode invalide n'a été identifié**, ce qui indique que, lorsque des ORPHAcodes étaient fournis, ils respectaient généralement les formats attendus et les standards de référence.

Par ailleurs, une proportion élevée de **codes ICD-10** (93,92 %) et **l'ensemble des codes ISCN** (100,00 %) présentaient des erreurs de validité. Ces taux élevés reflètent probablement des aspects structurels de la collecte des données plutôt que des problèmes systématiques de saisie.

Pour l'**ICD-10**, bien que les codes soient censés respecter une liste de référence prédéfinie, des cas ont été observés où des descriptions de maladies en texte libre étaient soumises sans code ICD-10 correspondant. Ce schéma peut en partie refléter l'absence de configurations de validation en amont dans le formulaire web HD4DP1 durant la période de reporting, lesquelles n'imposaient pas systématiquement la validation des formats ou des listes de référence lors de la soumission.

Dans le cas de l'**ISCN**, les codes étaient enregistrés exclusivement sous forme de texte libre dans le cadre de l'Architecture 1 et étaient donc intrinsèquement plus sujets à des erreurs de validité liées au format. De manière cohérente, des descriptions de maladies en texte libre sans code ISCN correspondant ont également été observées, contribuant davantage à la forte proportion de problèmes de validité détectés pour cette variable.

Les **codes postaux** ne correspondaient pas à la liste de référence dans 1,50 % de l'ensemble des enregistrements. Ce schéma reflète probablement une combinaison de facteurs, notamment des enregistrements incomplets, des limitations de la validation en amont dans le formulaire HD4DP1, ainsi que l'utilisation de codes postaux anciens, temporaires ou non résidentiels, plutôt qu'un usage systématique de codes postaux invalides.

Un format de **tranche d'âge** invalide a été observé dans 1,24 % de l'ensemble des enregistrements. Cela peut refléter une variabilité dans l'interprétation du texte d'aide du formulaire, combinée à l'absence de règles de validation de format appliquées en amont dans le formulaire HD4DP1 durant la période de reporting.

Pour **toutes les autres variables évaluées**, des erreurs de validité ou de fiabilité ont été observées dans moins de 1 % des enregistrements.

3.4. COHÉRENCE

Les **contrôles de cohérence** évaluent la logique des données enregistrées, à la fois au sein d'un même champ et entre des champs liés dans le CRRD. Alors que les contrôles de validité vérifient que chaque variable respecte les formats attendus et les plages de valeurs définies, les contrôles de cohérence portent sur la plausibilité des combinaisons de variables. Cette dimension de la qualité des données vise à garantir que les informations enregistrées reflètent des situations cliniques réalistes et non contradictoires. Les règles de cohérence incluent, par exemple, la vérification que le pays de référence correspond au pays du centre déclarant, ou que la base du diagnostic est cohérente avec la présence ou l'absence de symptômes rapportés.

Un aperçu des règles de cohérence appliquées à l'ensemble du registre est présenté dans le Tableau 9.

Table 9. Synthèse des indicateurs de cohérence inter-champs dans le CRRD (%).

Domaine	Indicateur de qualité des données	Pourcentage total d'enregistrements incohérents dans le CRRD (%)
Identification	Date de décès manquante (parmi les patients décédés)	0,06
Identification	Code postal = 9999 mais pays manquant	0,00
Identification	Code postal = 9999 mais pays = BE	0,01
Identification	Code postal = 999 mais pays renseigné	0,12
Consultation	Pays = BE mais ville = « hors Belgique »	0,00
Consultation	Pays = BE mais ville manquante	0,00
Consultation	Pays manquant mais ville renseignée de manière inattendue	0,00
Diagnostic	Absence de symptômes mais moment des premiers symptômes renseigné	0,00
Diagnostic	Absence de symptômes mais signes cliniques codés	0,00
Diagnostic	Base du diagnostic = « Autre » mais contenu non renseigné	0,27

Note: Le code de substitution « 9999 » doit être utilisé si le patient ne réside pas en Belgique, en combinaison avec le pays de résidence. Le code de substitution « 999 » correspond à des données manquantes.

Le Tableau 9 montre que les erreurs de cohérence inter-champs pour l'ensemble des variables évaluées étaient soit absentes, soit concernaient **moins de 1 %** des enregistrements, indiquant un niveau global élevé de cohérence interne au sein de la base de données du CRRD.

Parmi les patients décédés, la **date de décès** était manquante dans 0,06 % des enregistrements. Cette incohérence rare peut refléter une combinaison de facteurs, notamment l'absence ou le retard de mise à jour après l'enregistrement initial, ainsi que des limitations des règles de validation en amont qui n'imposaient pas systématiquement la complétion de ce champ lors de la soumission.

Il convient de noter que les informations relatives au statut vital ne sont pas encore collectées de manière systématique dans le cadre actuel du registre. Le CRRD enregistre chaque patient comme une entrée unique et ne prévoit pas de suivi systématique du statut vital dans le temps. Par conséquent, les centres déclarants mettent généralement à jour cette information uniquement lors de la correction ou de la mise à jour d'autres variables, étant donné que l'enregistrement du statut vital n'est pas obligatoire. En conséquence, tant l'exhaustivité que l'actualisation des données relatives au statut vital restent limitées, et les chiffres rapportés sont susceptibles de sous-estimer le nombre réel de patients décédés. Afin de remédier à cette limitation, une procédure de couplage avec le Registre national est actuellement en cours de développement, ce qui permettra une collecte systématique du statut vital et de la date de décès, le cas échéant.

Par ailleurs, un nombre limité de problèmes de cohérence a également été observé concernant les codes postaux utilisés pour indiquer le lieu de résidence, notamment une utilisation inappropriée des codes « 999 » et « 9999 » en combinaison avec des champs pays ou ville renseignés. Ces situations reflètent des incohérences sémantiques dans l'utilisation des codes de substitution, plutôt que des codes postaux incorrects, et sont restées peu fréquentes.

Enfin, 0,27 % des enregistrements indiquaient une **base du diagnostic** « *autre* » sans précision supplémentaire. Cette observation est cohérente avec le fait que la spécification de la catégorie « *autre* » n'est pas définie comme obligatoire.

3.5. QUALITÉ DU CODAGE DES MALADIES

3.5.1. APERÇU GÉNÉRAL

L'évaluation de la qualité du codage des maladies examine l'utilisation et la validité des systèmes de classification des maladies standardisés dans le CRRD. Un codage précis et harmonisé est essentiel pour garantir l'interopérabilité des données relatives aux maladies rares, tant au niveau national qu'international.

Depuis sa mise en œuvre, le CRRD prend en charge plusieurs systèmes de codage, les ORPHAcodes constituant la norme principale de classification et la référence internationale pour les maladies rares, conformément aux recommandations de la Commission européenne.

D'autres systèmes de codage et ontologies (à savoir ICD-10, SNOMED CT, ICD-O, HPO, OMIM, ISCN, LOINC) sont utilisés comme références complémentaires afin de renforcer l'interopérabilité et de faciliter le mapping avec des jeux de données cliniques, épidémiologiques et génétiques, permettant ainsi de capturer des informations phénotypiques et génétiques supplémentaires.

Le Tableau 10 présente la répartition des systèmes de codage des maladies et des ontologies utilisés au sein du registre, ainsi que leur évolution sur la période de reporting 2015–2025. Les pourcentages de couverture sont calculés comme des moyennes pondérées entre centres, en utilisant le nombre d'enregistrements par centre et par année comme pondération. En conséquence, les centres contribuant avec des volumes plus importants ont une influence proportionnellement plus élevée sur les estimations globales agrégées. Les pourcentages sont calculés indépendamment pour chaque système de codage et ne sont donc **pas mutuellement exclusifs**, plusieurs systèmes de codage pouvant être renseignés pour un même enregistrement.

Table 10. Répartition des systèmes de codage des maladies et des ontologies utilisés dans le CRRD.

Année	Couverture ORPHAcodé (%)	Couverture SNOMED CT (%)	Couverture ICD-10 (%)	Couverture HPO (%)	Couverture OMIM (%)	Couverture ISCN (%)	Sans code (%)
2015	100,00	0,00	0,00	0,00	0,00	0,00	0,00
2016	97,29	0,00	5,34	2,22	1,18	0,00	0,00
2017	98,53	0,00	5,88	0,00	0,48	0,00	0,00
2018	78,44	20,83	0,50	0,00	0,76	0,00	0,00
2019	83,14	14,19	0,00	7,78	1,83	0,03	0,14
2020	76,44	22,11	0,00	0,23	1,34	0,00	0,52
2021	72,60	25,82	0,00	0,00	0,09	0,00	1,50
2022	81,48	5,70	0,00	6,86	10,92	0,00	4,42
2023	58,26	9,75	0,05	0,00	1,41	0,00	31,02
2024	99,60	0,00	0,00	0,00	0,40	0,00	0,40
2025	80,61	2,99	0,00	62,71	19,28	0,07	0,70

Pour l'ensemble des enregistrements soumis dans le cadre de l'Architecture 1 (2015–2025), les **ORPHA**codes sont restés le système de classification des maladies dominant tout au long de la période de reporting, reflétant leur rôle de standard de référence international pour les maladies rares. Il convient toutefois de noter que cela reflète **uniquement l'utilisation dans le contexte du registre**. Alors que certains centres utilisent les ORPHAcodes de manière routinière dans leurs DSE, d'autres les appliquent exclusivement à des fins de reporting dans le CRRD ou ont recours à un transcodage manuel afin de se conformer aux recommandations du registre. Par ailleurs, les enregistrements soumis sans ORPHAcode étaient renvoyés aux centres via la boucle de validation lorsque cela était possible, ce qui peut également contribuer au niveau élevé de couverture des ORPHAcodes observé dans le jeu de données du CRRD.

D'autres systèmes de codage et ontologies ont également été utilisés pour soumettre des enregistrements au CRRD, soit seuls, soit en complément des ORPHAcodes. La couverture de **SNOMED CT** a augmenté progressivement et a atteint un pic de 25,8 % en 2021, reflétant son rôle croissant en tant que terminologie clinique de référence.

La couverture **OMIM** a atteint un pic de 10,9 % en 2022, tandis que la couverture **HPO** a atteint un maximum de 62,7 % en 2025. Cette valeur agrégée élevée reflète une utilisation concentrée de HPO dans au moins un centre à fort volume, plutôt qu'une adoption homogène entre tous les centres. Contrairement aux systèmes de classification des maladies, les ontologies telles que **OMIM et HPO** sont conçues pour décrire des caractéristiques génétiques et phénotypiques et sont donc **généralement utilisées plusieurs fois au sein d'un même enregistrement**. Par exemple, une entrée OMIM pour un diagnostic clinique peut référencer plusieurs gènes et phénotypes associés, tandis que HPO permet de décrire le profil phénotypique d'un patient à l'aide de plusieurs termes caractérisant les manifestations cliniques, leur sévérité et leur apparition. Ainsi, la présence de multiples termes OMIM ou HPO dans un même enregistrement de patient est attendue et reflète l'utilisation appropriée et prévue de ces ontologies.

La couverture **ICD-10** est restée limitée tout au long de la période de reporting et a atteint un pic de 5,9 % en 2017, après quoi aucun enregistrement codé en ICD-10 n'a été soumis. La disparition du codage ICD-10 dans les soumissions au CRRD à partir de 2019 est cohérente avec la transition nationale en cours vers l'ICD-11, soutenue par l'utilisation accrue de SNOMED CT comme terminologie clinique de référence. Cette transition devrait être finalisée d'ici 2027.

ISCN, le standard de référence pour la description des anomalies chromosomiques humaines, n'a été utilisé qu'en 2019 et 2025, indiquant une couverture limitée sur l'ensemble de la période de reporting.

Dans l'ensemble, ces tendances illustrent une convergence progressive vers les ORPHAcodes comme système principal de classification des maladies rares au sein du CRRD, parallèlement à une utilisation évolutive de systèmes de codage complémentaires reflétant des évolutions plus larges, tant au niveau national qu'international, en matière d'interopérabilité des données.

4. ANALYSE GLOBALE DU PROCESSUS DE VALIDATION

Ce chapitre examine la performance du processus de validation appliqué aux soumissions du CRRD dans le cadre de l'Architecture 1 (v1–v3). Alors que le chapitre précédent se concentre sur la qualité de l'ensemble des données soumises, ce chapitre analyse les principaux indicateurs liés au processus de validation des données du CRRD.

L'ensemble des enregistrements passe par un flux de travail en deux niveaux au sein de l'infrastructure Healthdata.be :

- **Validation en amont** (HD4DP), où les champs obligatoires, les règles de format et les ensembles de valeurs empêchent la soumission d'enregistrements structurellement invalides ; et
- **Validation en aval** (HD4RES/SAS), où des contrôles logiques supplémentaires, des vérifications inter-champs et des contrôles liés au codage des maladies sont appliqués après réception des données.

Ce chapitre présente une synthèse des résultats de ces étapes de validation, y compris la distribution des indicateurs du processus de validation, les types d'erreurs les plus fréquents ainsi que les resoumissions générées dans le cadre de la boucle de validation. Ces éléments permettent d'évaluer dans quelle mesure le processus de validation contribue à l'amélioration de la qualité des données au sein du registre.

4.1. MÉTHODOLOGIE

Au niveau des fournisseurs de données, l'application HD4DP applique des règles de validation en amont intégrées dans le formulaire électronique de collecte des données. Ces règles incluent des champs obligatoires, des restrictions de format et des listes déroulantes visant à empêcher la soumission d'enregistrements incomplets ou structurellement invalides. Les enregistrements ne respectant pas ces critères ne peuvent pas être transmis au registre.

Une fois soumis, les enregistrements sont traités au moyen d'une série de règles de validation en aval mises en œuvre par l'équipe de recherche de Sciensano via SAS Enterprise Guide. Ces contrôles incluent des règles logiques supplémentaires, des vérifications liées au codage des maladies et des contrôles de cohérence inter-champs, allant au-delà des validations en amont et appliquées au jeu de données consolidé après réception des données. Ce second niveau de validation garantit que les données soumises respectent les définitions de données du CRRD, s'alignent sur les classifications de référence et maintiennent une cohérence interne.

Chaque enregistrement est ensuite classé selon son statut de validation :

- **Validé** : enregistrements respectant l'ensemble des critères requis en matière de format, d'exhaustivité et de cohérence, et pouvant ainsi être intégrés dans l'entrepôt de données (DWH) du registre ;
- **Correction requise** : enregistrements contenant des informations incomplètes ou incohérentes nécessitant des clarifications de la part du fournisseur de données. Ces enregistrements sont temporairement rejetés et renvoyés au fournisseur de données pour correction via la boucle de validation vers la plateforme HD4DP1. Une fois corrigés et resoumis, ils peuvent être validés et intégrés dans l'entrepôt de données du registre ;
- **Rejeté** : enregistrements définitivement rejetés en raison d'erreurs critiques liées à la structure ou au contenu, y compris les doublons ou les enregistrements ne répondant pas aux critères d'inclusion du CRRD. Ces enregistrements ne sont pas éligibles à l'analyse et ne sont pas intégrés dans l'entrepôt de données du registre.

Les enregistrements identifiés comme « Correction requise » sont renvoyés aux fournisseurs de données via la boucle de validation de l'Architecture 1, permettant un processus itératif de révision et de resoumission. Chaque resoumission est considérée comme un nouvel enregistrement entrant et est comptabilisée séparément dans le nombre total d'enregistrements. En conséquence, le nombre d'enregistrements soumis est supérieur au nombre de patients uniques inclus dans le CRRD.




Figure 3. Aperçu du flux de validation des données à deux niveaux appliqué dans le CRRD (Architecture 1).

La Figure 3 illustre le flux de travail séquentiel et itératif du processus de validation appliqué via l'infrastructure Healthdata.be pour les soumissions de données du CRRD dans le cadre de l'Architecture 1. Ce processus combine des règles de validation en amont au niveau des fournisseurs de données (HD4DP) avec une validation en aval réalisée par l'équipe de recherche du CRRD (HD4RES). Ce système de validation à deux niveaux, associant des contrôles préventifs lors de la soumission et des contrôles analytiques après soumission, vise à assurer une amélioration progressive et une harmonisation de la qualité des données entre l'ensemble des centres participants.

4.2. INDICATEURS DU PROCESSUS DE VALIDATION

Cette section présente la distribution et l'évolution des indicateurs du processus de validation pour l'ensemble des soumissions de données entre 2015 et 2025, offrant une vue d'ensemble de l'évolution de la qualité des données du registre au cours de la période de reporting. Elle synthétise à la fois les tendances globales de validation (reflétant l'ensemble des enregistrements soumis) et les schémas de validation liés au codage des maladies, qui constituent une source majeure de retours et d'activités de correction au sein du CRRD.

4.2.1. TENDANCES GLOBALES DE VALIDATION

Le Tableau 11 présente l'évolution annuelle des indicateurs du processus de validation, incluant le nombre total d'enregistrements, le nombre de patients uniques représentés, le nombre moyen d'enregistrements par patient ainsi que la proportion de validations à la première tentative et à tentatives multiples.

Ces indicateurs reflètent le caractère itératif du processus de validation, par lequel les fournisseurs de données améliorent progressivement la qualité de leurs données grâce aux retours et aux resoumissions. Ils fournissent également un aperçu de la charge de travail opérationnelle pour les fournisseurs de données, chaque erreur de validation générant des étapes supplémentaires de révision, de correction et de resoumission.

La prise en compte de cette charge de travail est essentielle pour interpréter correctement les indicateurs de validation, car un nombre élevé de resoumissions peut à la fois refléter des problèmes initiaux de qualité des données et les efforts soutenus des fournisseurs de données pour y remédier dans le cadre de la boucle de validation de l'Architecture 1.

Table 11. Indicateurs annuels du processus de validation et distribution globale du statut des enregistrements (2015–2025).

Année	Nombre total d'enregistrements (N)	Patients uniques (N)	Nombre moyen d'enregistrements par patient N (ET)	Validations à la première tentative (%)	Validations à tentatives multiples (%)
2015	1	1	1,0 (NA)	100,0	0,0
2016	10 802	374	28,9 (55,1)	44,7	55,3
2017	2 666	1 307	2,0 (1,9)	95,2	4,8
2018	3 792	707	5,4 (3,5)	92,8	7,2
2019	26 864	3 584	7,5 (3,4)	51,3	48,7
2020	9 521	4 741	2,0 (3,0)	96,9	3,1
2021	2 320	949	2,4 (0,4)	91,7	8,3
2022	10 415	5 273	2,0 (2,3)	95,3	4,7
2023	4 070	2 796	1,5 (0,6)	95,1	4,9
2024	1 496	1 304	1,1 (0,4)	95,3	4,7
2025	4 947	942	5,3 (3,7)	95,4	4,6

Note: Le nombre moyen d'enregistrements par patient est calculé en faisant la moyenne des valeurs moyennes par centre pour chaque année. L'écart-type rapporté représente la dispersion de ces valeurs au niveau des centres entre les fournisseurs de données.

L'unique enregistrement en **2015** reflète l'activité durant la phase de POC menée entre décembre 2013 et juin 2015 avec deux centres pilotes (à savoir les centres de génétique affiliés au CHU de Liège et à l'UZ Gent).

En 2016, un nombre moyen élevé d'enregistrements par patient (28,9) a été observé, ainsi qu'une proportion relativement élevée de validations à tentatives multiples (55,3 %). Ce schéma reflète probablement la phase initiale d'intégration à grande échelle, durant laquelle les fournisseurs de données ont dû faire face à une charge de travail importante en matière d'enregistrement tout en se familiarisant avec la DCD et l'interface de soumission HD4DP1.

À partir de 2017, le nombre moyen d'enregistrements par patient a fortement diminué et a ensuite légèrement fluctué, tandis que la proportion de validations à la première tentative a augmenté de manière significative. Cette tendance suggère une amélioration progressive de l'efficacité de l'enregistrement et de la qualité des données, probablement liée à une meilleure familiarité avec les exigences du registre, aux retours itératifs dans le cadre de la boucle de validation, ainsi qu'à une harmonisation progressive des pratiques de saisie des données.

Une exception à cette tendance générale a été observée en **2019**, où 48,7 % des enregistrements ont nécessité des validations à tentatives multiples. Cette augmentation coïncide avec la mise en œuvre de la **DCD v3.0**, qui a introduit des modifications structurelles et sémantiques du jeu de données et a nécessité une période d'adaptation pour les fournisseurs de données. L'augmentation temporaire des resoumissions reflète donc une phase de transition plutôt qu'une détérioration de la qualité des données.

La Figure 4 complète le Tableau 11 en illustrant la distribution des indicateurs de validation à la première tentative et à tentatives multiples sur l'ensemble de la période de reporting, mettant en évidence l'évolution globale vers des taux plus élevés de validation à la première tentative au fil du temps.




Figure 4. Répartition des validations à la première tentative et à tentatives multiples (2015–2025).

4.2.2. TENDANCES DE VALIDATION LIÉES AU CODAGE DES MALADIES

Une analyse plus approfondie des validations à tentatives multiples montre qu’une proportion importante des demandes de correction au cours de la période de reporting était liée à des incohérences dans le codage des maladies, en particulier concernant les **ORPHAcodes**, qui constituent le système de référence principal utilisé dans le CRRD pour la classification des maladies rares et s’alignent sur les standards internationaux de nomenclature des maladies rares.

Ces corrections concernaient le plus souvent des **ORPHAcodes manquants, des ORPHAcodes invalides ou des incohérences entre le nom de la maladie enregistré et l’ORPHAcode associé.**

Dans le cadre du processus de validation, les enregistrements étaient donc renvoyés aux centres d’enregistrement lorsque l’ORPHAcode était manquant, invalide ou incohérent avec le nom de la maladie enregistré, même si un autre code de maladie avait été fourni.

La Figure 5 présente la proportion de l’ensemble des corrections de validation attribuables à des problèmes liés aux ORPHAcodes au fil du temps. Elle permet d’évaluer la contribution relative de la qualité du codage des maladies, spécifiquement liée aux ORPHAcodes, à l’ensemble des corrections de validation (c’est-à-dire toutes les corrections, et non uniquement celles liées au codage des maladies) et fournit un aperçu de l’évolution des schémas de validation liés aux ORPHAcodes au cours de la période de reporting.




Figure 5. Proportion des corrections de validation liées aux problèmes d'ORPHAcode (2015–2025).

La Figure 5 met en évidence une **augmentation marquée du nombre absolu de corrections de validation en 2019**. Ce pic coïncide avec une hausse significative du nombre total d'enregistrements cette année-là (voir Tableau 2), à la suite du lancement du CRRD v3.0 en 2018, qui a introduit une structure de données plus stable et permis des soumissions de données à grande échelle par les centres participants. L'augmentation observée des corrections reflète donc à la fois une hausse du volume d'enregistrements et une période d'appropriation attendue liée à l'introduction d'une DCD révisée, plutôt qu'une détérioration de la qualité des données.

La valeur de 0 % observée en 2016 reflète le nombre très limité de demandes de correction enregistrées durant la phase initiale de mise en œuvre du CRRD. Bien que plusieurs validations à tentatives multiples aient eu lieu cette année-là (voir Figure 4), seuls deux enregistrements ont finalement été renvoyés aux centres d'enregistrement pour correction, et aucune de ces corrections ne concernait des problèmes liés aux ORPHAcodes. Cela reflète probablement la phase opérationnelle initiale du registre, au cours de laquelle les procédures de validation et les boucles de validation étaient encore en cours de mise en place progressive.

En termes de composition, la **proportion de corrections liées aux ORPHAcodes était la plus élevée en 2019 (89,0 %), 2024 (94,3 %) et 2025 (73,5 %)**. Ces proportions élevées reflètent le rôle central des ORPHAcodes dans le processus de validation et leur vérification systématique lors de la soumission des données. Il est important de noter que, malgré la proportion relative élevée observée en 2024, le nombre absolu de corrections cette année-là est resté très faible. Les données pour 2025 doivent être interprétées avec prudence, car elles incluent uniquement les enregistrements soumis jusqu'en juin 2025, correspondant aux derniers mois de l'Architecture 1. Les tendances observées pour 2025 reflètent donc une activité partielle et non un cycle complet de reporting.

Dans l'ensemble, les corrections liées aux ORPHAcodes ont représenté une part importante du retour de validation tout au long de la période de reporting, reflétant à la fois leur rôle central dans la classification des maladies rares et le processus itératif d'harmonisation inhérent à la maturation du registre.

5. SYNTHÈSE DES PRINCIPAUX RÉSULTATS

Les analyses présentées dans la Partie I du Rapport de benchmark sur la qualité des données fournissent une vue d'ensemble globale consolidée de la qualité des données au sein du CRRD dans le cadre de l'Architecture 1, sur base des enregistrements soumis entre 2015 et 2025 par les centres de génétique agréés en Belgique. Dans leur ensemble, les résultats mettent en évidence un registre en maturation, caractérisé par une exhaustivité des données globalement élevée, une cohérence importante et une amélioration progressive des indicateurs du processus de validation au fil du temps (par exemple, une augmentation de la proportion de validations à la première tentative).

Au niveau agrégé global, plusieurs points forts se dégagent. Les variables liées à l'Identification et à la Consultation présentent systématiquement des niveaux d'exhaustivité élevés, reflétant une bonne capture des informations administratives et cliniques essentielles dans l'ensemble des centres. Les contrôles de validité, de fiabilité et de cohérence inter-champs révèlent des taux d'erreur très faibles pour la majorité des variables évaluées, indiquant un niveau élevé de cohérence interne et de plausibilité des données enregistrées. Par ailleurs, l'augmentation des taux de validation à la première tentative au fil des années suggère une amélioration progressive de l'efficacité de l'enregistrement et une meilleure appropriation des exigences du registre par les fournisseurs de données.

L'analyse met également en évidence le rôle central des ORPHAcodes au sein du CRRD. Les ORPHAcodes sont restés le système de classification des maladies dominant tout au long de la période de reporting et, lorsqu'ils étaient fournis, ils respectaient généralement les standards de référence attendus. Bien que le codage des maladies ait représenté une part importante du retour de validation — en particulier lors des périodes de transition du registre — ces tendances reflètent principalement la complexité de la classification des maladies rares et le processus itératif d'harmonisation inhérent au développement du registre, plutôt que des lacunes persistantes en matière de qualité des données. Par ailleurs, l'absence d'utilisation systématique des ORPHAcodes dans les DSE hospitaliers a nécessité une attribution rétrospective, contribuant probablement à la proportion élevée de corrections liées aux ORPHAcodes.

Dans le même temps, cette vue d'ensemble globale met en évidence plusieurs domaines prioritaires d'amélioration. Ceux-ci incluent une exhaustivité variable pour certains champs diagnostiques, une hétérogénéité des pratiques de codage des maladies entre les centres, ainsi que la charge opérationnelle associée aux processus de validation et de resoumission. Certains des problèmes observés sont liés aux caractéristiques structurelles ou techniques du cadre de collecte des données sous l'Architecture 1, telles qu'une validation en amont limitée, le recours à des champs en texte libre et l'évolution des DCD. Ces constats soulignent l'importance d'aligner les définitions des variables avec la disponibilité des données dans les DSE et de renforcer, lorsque cela est possible, les mécanismes de validation automatisés. Une attention particulière doit être accordée aux variables « *moment du diagnostic actuel* » et « *moment des premiers symptômes* », pour lesquelles les résultats suggèrent des difficultés de capture de ces informations cliniques, probablement en raison d'une disponibilité limitée ou d'une incertitude rétrospective dans les DSE.

Il est important de noter que la variabilité observée au niveau agrégé global doit être interprétée dans son contexte, en tenant compte des différences de flux de travail locaux, des phases historiques d'intégration et des périodes de transition liées aux mises à jour des spécifications du registre. La prise en compte de ces facteurs représente une opportunité d'harmoniser davantage les pratiques et d'améliorer la comparabilité des données du CRRD.

Dans ce contexte, les analyses de benchmarking spécifiques à chaque centre (Partie II) apportent une perspective complémentaire en permettant à chaque centre participant d'évaluer ses propres indicateurs de qualité des données au regard de tendances globales pseudonymisées. Ensemble, la vue d'ensemble globale et les analyses au niveau des centres visent à soutenir un dialogue constructif, des actions ciblées d'amélioration de la qualité et la maturation continue du CRRD en tant que ressource nationale fiable.

6. CONCLUSION

S'appuyant sur la synthèse globale présentée dans la Partie I, les résultats de cette première édition du Rapport de benchmark sur la qualité des données du CRRD reflètent les progrès substantiels réalisés au cours de plus d'une décennie de collaboration continue entre Sciensano, les centres de génétique agréés et les partenaires institutionnels impliqués dans le développement et le fonctionnement du CRRD. Depuis ses débuts en tant qu'initiative de POC, le CRRD évolue progressivement vers un système national de surveillance des maladies rares, capable de soutenir le suivi épidémiologique, l'amélioration de la qualité des données et l'élaboration des politiques dans le domaine des maladies rares, tout en poursuivant sa maturation en termes de couverture, de pertinence et de robustesse.

Les analyses mettent néanmoins en évidence la nécessité de poursuivre les efforts d'amélioration, soulignant le travail encore requis pour exploiter pleinement le potentiel du CRRD et assurer sa durabilité à long terme. L'amélioration de la qualité des données nécessite des efforts coordonnés à tous les niveaux du flux de données, incluant une saisie des données précise et complète au niveau des centres ; l'amélioration continue de la DCD afin de favoriser une interprétation cohérente des définitions des variables et leur alignement avec les données disponibles dans les DSE ; le renforcement des règles de validation en amont ; un investissement soutenu dans l'infrastructure technique ; ainsi qu'un soutien accru aux fournisseurs de données. La prise en compte de la variabilité observée en matière de pratiques de codage des maladies, d'exhaustivité, de fiabilité et de validité, de cohérence et d'indicateurs du processus de validation restera essentielle pour harmoniser davantage les pratiques de reporting et améliorer la fiabilité des indicateurs nationaux du CRRD.

Il est important de souligner que la qualité des données observée dans le cadre de l'Architecture 1 a bénéficié d'une boucle de validation itérative ayant permis une harmonisation progressive des pratiques de soumission des données au sein et entre les centres. Dans le cadre de l'Architecture 2 (à partir de septembre 2024), ce mécanisme de retour n'est plus intégré au flux de données standard, ce qui renforce l'importance de la qualité des données à la source et des pratiques en amont, plutôt que des corrections post-soumission. En cohérence avec l'évolution de la vision nationale en matière de registres de santé, cette transition met davantage l'accent sur la *qualité à la source* et la disponibilité proactive de données exactes, complètes et interprétables dès la première soumission. Le maintien d'un haut niveau de qualité des données repose donc de plus en plus sur des éléments de données clairement définis, des standards partagés (par exemple, le codage des maladies), des systèmes interopérables et une collaboration continue entre l'ensemble des parties prenantes.

À plus long terme, plusieurs développements en cours ou planifiés offrent des perspectives importantes d'amélioration. L'intégration progressive des RDFs reconnues au niveau national dans le CRRD devrait élargir la portée du registre et contribuer à une capture plus complète de la population nationale atteinte de maladies rares. Parallèlement, la mise en œuvre du Plan belge pour les maladies rares (2026–2030), mettant l'accent sur la standardisation, l'intégration numérique et l'interopérabilité des données, devrait renforcer davantage la qualité, l'exhaustivité et l'utilisabilité des données relatives aux maladies rares.

Ensemble, ces évolutions devraient progressivement améliorer la couverture nationale des patients atteints de maladies rares et permettre au CRRD de refléter plus fidèlement le paysage épidémiologique en Belgique. La poursuite de la collaboration et de l'engagement commun entre les parties prenantes restera essentielle pour soutenir ces avancées et garantir que le CRRD continue de se développer en tant que ressource nationale robuste, fiable et pertinente pour les politiques publiques dans le domaine des maladies rares.

7. RÉFÉRENCES

1. Ces centres correspondent aux centres de génétique agréés en Belgique, tels que définis par l'Arrêté royal de 2008 établissant le réseau des services de génétique médicale.
2. Dhondt E, Jirari A, Demeulemeester N, Wuyts J. Central Registry of Rare Diseases (CRRD), Data Collection Report (1st Edition 2015–2025). Brussels, Belgium: Sciensano; 2026. 97p. Report reference number: D/2026.14.440/6.
3. Pour plus d'informations, veuillez consulter: <https://docs.healthdata.be/HDBP0008>.
4. Pour plus d'informations, veuillez consulter: <https://www.ehealth.fgov.be/ehealthplatform/file/cc73d96153bbd5448a56f19d925d05b1379c7f21/8b1b2e5884f4b3bae0045e3f81cfeb5a030faca2/15-009-f102-hd4patient-modifiee-le-3-mars-2020.pdf>.
5. Pour plus d'informations, veuillez consulter: <https://healthdata.sciensano.be/fr/l-architecture-technique-de-healthdatabe>.
6. Extrait du texte d'aide des DCD v1–v3: "Une maladie peut être décrite à l'aide de différents systèmes de codage. **La préférence est donnée à l'utilisation de la classification Orphanet, car il s'agit du système de classification le plus complet et le plus précis pour les maladies rares.** Si plusieurs systèmes de codage sont utilisés pour décrire la maladie, différents codes peuvent être introduits dans les champs correspondants. Il est obligatoire de remplir au moins un de ces champs...".

CONTACT

Amina Jirari • amina.jirari@sciensano.be • T +32 2 642 58 03

Evy Dhondt • evy.dhondt@sciensano.be • T +32 2 642 55 81

POUR PLUS D'INFORMATIONS

—
Veuillez visiter notre site web
<https://www.sciensano.be/fr/sujets-sante/maladies-rares>

Sciensano • Rue Juliette Wytsmanstraat 14 • 1050 Brussels • Belgium • T + 32 2 642 51 11 • T press + 32 2 642 54 20 •
info@sciensano.be • www.sciensano.be

—
Responsible publishers: Christian Léonard, Managing director • Rue Juliette Wytsmanstraat 14 • 1050 Brussels • Belgium •